

Paper:

学生主体PBLによるRGB画像を用いたトマト糖度・酸度統合推定システムの開発

著者名 [要確認]

所属機関 [要確認]

住所 [要確認]

E-mail: メールアドレス [要確認]

[Received 2026/07/15; accepted 2026/07/15]

農業分野では、後継者不足や熟練者の経験知への依存が課題となっている。トマトの糖度および酸度は、食味や商品価値に関係する重要な品質指標であるが、これらの測定には果汁の採取や専用機器を必要とする場合があり、多数の果実を継続的に評価するには相応の作業を要する。本研究では、汎用的なRGB画像からトマトを検出し、糖度および酸度を同時に推定する統合型AIシステムを開発した。提案するUnifiedDetectorは、YOLOv10sを基盤とする物体検出器、中間特徴量抽出、RoI Align、および回帰ヘッドによって構成される。物体検出器によって特定したトマト領域の特徴量を回帰ヘッドへ入力することで、果実検出、糖度推定、酸度推定を一連の処理として実行する。検証用データセット136サンプルを用いた評価の結果、酸度推定では、平均絶対誤差0.0897、平均二乗誤差平方根0.1484、決定係数0.1171、相関係数0.3707が得られた。従来のSwin Transformerモデルと比較して、平均絶対誤差は82.0%、平均二乗誤差平方根は74.4%低減した。糖度推定では、平均絶対誤差0.5860 Brix、平均二乗誤差平方根0.8397 Brix、決定係数0.2288、相関係数0.8434が得られた。これらの結果から、提案モデルは糖度の相対的な変化を捉えるとともに、従来モデルと比較して酸度推定性能を改善できることを確認した。また、本研究は、学生が農業従事者へのヒアリング、画像収集、品質測定、AIモデル設計、実装、評価までを担当するProject-Based Learningとして実施した。本論文は、このPBL活動によって得られた技術成果と、農業、画像処理、深層学習、システム設計、統計評価を横断した開発プロセスを示すものである。

Keywords: スマート農業、トマト、糖度・酸度推定、深層学習、Project-Based Learning

1. Introduction

農業分野では、作物の生育状態、収穫時期、灌水、施肥などの判断に、農業従事者が長年の経験を通じて獲得した知識が用いられている。このような知識は、必ずしも数値や文章として整理されておらず、熟練者個人の暗黙知として保持される場合が多い。そのため、新規就農者や後継者へ判断基準を継承することは容易ではない。

本研究グループでは、複数の農業従事者に対してヒアリングを実施した。その結果、後継者不足、経験値への依存、および紙の作業日誌や書類を中心としたアナログ

な作業文化が、農業現場における主な課題として挙げられた。そこで本プロジェクトでは、作物の状態や農作業の内容をデータとして記録し、AIや情報通信技術によって農業従事者の判断を支援するシステムの構築に取り組んだ。

トマトの品質は、外観、大きさ、硬度、成熟度、糖度、酸度などの指標によって評価される。特に糖度と酸度は、甘味と酸味のバランスに関係し、食味や商品価値を判断する上で重要な指標である。糖度は、一般に果汁を屈折糖度計へ滴下し、Brix値として測定する。酸度についても、滴定法や専用の測定機器を用いる場合がある。これらの方法は客観的な数値を取得できる一方、測定対象ごとに果汁を採取する必要がある、多数の果実を継続的に確認する用途では一定の作業負担が生じる。

果実品質を非破壊で推定する手法として、近赤外分光やハイパースペクトル画像を用いる研究が行われている。Xiangらは、チェリートマトの可溶性固形分および硬度を、ハイパースペクトル画像と深層学習を用いて推定した[1]。Zhaoらは、加工用トマトの硬度、可溶性固形分、リコピン含有量、滴定酸度、成熟段階を、近赤外ハイパースペクトル画像と機械学習によって推定した[2]。Daiらは、ハイパースペクトル画像を用いてトマトの成熟度を識別し、リコピン含有量を予測した[3]。また、de Britoらは、携帯型Vis-NIR分光計を用いて、トマトの色、滴定酸度、乾物量の非破壊推定を検討した[4]。これらの研究は、光学的な情報がトマト品質の推定に利用できることを示している。

一方、ハイパースペクトルカメラや分光計は、一般的なRGBカメラと比較して専用性が高い。一般的なカメラやスマートフォンで取得できるRGB画像から品質の傾向を推定できれば、より導入しやすい品質評価支援システムを構築できる可能性がある。

RGB画像を用いたトマトの検出や成熟度推定についても研究が行われている。Kimらは、RGBカメラで撮影したトマト画像を用い、深層ニューラルネットワークによって成熟度を推定した[5]。Liらは、MHSA-YOLOv8を用いて、トマトの成熟度検出と個数推定を行った[6]。Khanらは、CNNとTransformerを組み合わせたモデルによって、複雑な背景を含むトマト画像の成熟度を認識した[7]。Wangらは、深層学習に基づくトマト成熟度検出モデルを提案した[8]。これらの研究から、RGB画像には、果実の色、形状、表面状態、成熟度などに関する情報が含まれることが示されている。

農業における深層学習は、病害検出、作物分類、果実検出、収量予測などへ応用されている[9]。また、AIと

IoT を統合することで、作物や圃場の状態を継続的に把握し、農業従事者の意思決定を支援する研究も進められている [10].

本研究では、RGB 画像からトマトを検出し、検出領域の特徴量を利用して、糖度および酸度を同時に推定する統合型 AI システムを開発した。従来構築したシステムでは、Swin Transformer を用いた個別の回帰モデルによって糖度および酸度を推定していた。これに対し、本研究では、YOLOv10s の中間特徴量、RoI Align, および回帰ヘッドを統合した UnifiedDetector を構築した。

本研究の主な貢献は、以下の 3 点である。

第一に、RGB 画像からトマトを検出し、糖度および酸度を同時に推定する統合型 AI システムを構築した。

第二に、136 サンプルの検証用データを用いて推定性能を定量的に評価し、従来の Swin Transformer モデルと比較した。

第三に、農業従事者へのヒアリングから AI モデルの評価までを学生主体で実施し、複数分野の技術を統合した PBL 活動の成果として、実際に動作するスマート農業システムを構築した。

STEM 分野における Project-Based Learning は、創造性や問題解決に関係する学習活動として研究されている [11]。また、工学系学生を対象とした STEAM 型 PBL では、協働、問題解決、創造的思考などの能力との関係が報告されている [12]。本研究は、あらかじめ定められた実験を再現する活動ではなく、学生が農業従事者へのヒアリングを通して課題を設定し、独自にデータを収集してシステムを構築した PBL 活動である。

なお、本プロジェクト全体には、環境センサデータ、BLE 測位、電子 MAP、および収穫支援技術に関する構想が含まれる。本論文では、RGB 画像を用いたトマトの糖度・酸度推定に対象を限定し、これらの機能は本研究の評価範囲に含めない。

2. System Design and Implementation

2.1. 設計方針

本システムは、低コスト性、統合性、拡張性、および PBL における実装可能性の 4 点を設計方針とした。

低コスト性については、ハイパースペクトルカメラや近赤外分光計ではなく、汎用的な RGB カメラで取得した画像を使用する。これにより、教育機関や小規模な農業実証にも導入しやすい構成とした。

統合性については、トマト検出、糖度推定、酸度推定をそれぞれ独立したシステムとして実行するのではなく、一つの処理パイプラインへ統合した。入力画像からトマトを検出し、検出された果実ごとに糖度と酸度を出力する (図 1)。

拡張性については、推定結果を外部システムへ受け渡せる構成とした。この構成により、クラウドシステム、栽培記録、位置情報などとの接続が可能となる。ただし、本論文の評価対象は画像を用いた推定機能である。

PBL における実装可能性については、学生がデータ収集、アノテーション、AI モデル設計、学習、評価、結果分析までを実施できるよう、Python および一般的な深層学習フレームワークを用いて開発した。

2.2. PBL による開発体制

本システムは、学生主体の Project-Based Learning として開発した。本活動では、教員から与えられた仕様を実装するのではなく、学生が農業従事者へのヒアリングを行い、現場における課題を整理した。その結果を基に、トマト品質評価を支援する画像 AI システムを開発対象として設定した。

開発では、AI、デバイス、アプリケーション、バックエンドなどの担当を設けた。AI 担当は、画像データの整理、アノテーション、モデル設計、学習、評価を担当した。デバイス担当は、トマト画像の取得条件および糖度・酸度の測定方法を検討した。アプリケーションおよびバックエンド担当は、推定結果の保存、表示、利用方法について検討した。

各担当は独立して作業するのではなく、データ形式、入力条件、出力形式、利用者への提示方法を共有しながら開発を進めた。このように、本活動では、農業上の課題設定からシステム評価までを一つの PBL として実施した (図 2)。

2.3. システム概要

提案システムは、画像取得、トマト検出、中間特徴量抽出、領域特徴量抽出、糖度・酸度推定、結果表示の 6 段階から構成される。

まず、1 個または複数個のトマトが写った RGB 画像を取得する。取得した画像を YOLOv10s を基盤とする物体検出器へ入力し、画像内のトマトの位置を境界ボックスとして取得する。

物体検出と同時に、YOLOv10s の Layer 16 から中間特徴マップを取得する。物体検出器の中間特徴には、入力画像から抽出された色、輪郭、形状、表面模様などに関係する情報が含まれる。

検出された境界ボックスと中間特徴マップを RoI Align へ入力し、各トマト領域に対応する特徴量を一定のサイズへ変換する。抽出された特徴量を RegressionHead へ入力し、糖度および酸度を連続値として出力する。

最後に、入力画像上へ境界ボックス、糖度予測値、酸度予測値、検出信頼度を描画する。これにより、一つの画像内に複数のトマトが存在する場合でも、果実ごとに予測結果を対応付けて表示できる。

2.4. データ収集および品質測定

本研究では、[品種名・要確認] のトマトを対象として、RGB 画像と糖度・酸度の実測値を収集した。画像の総数は [要確認] 枚、測定したトマトの個体数は [要確認] 個である。

画像撮影には [カメラまたはスマートフォンのメーカー・型番・要確認] を使用した。画像解像度は [要確認] pixel であり、撮影場所は [要確認] である。背景、照明、撮影距離、撮影方向などの撮影条件は [要確認] とした。

画像撮影後、各トマトの糖度および酸度を測定した。糖度は [糖度計のメーカー・型番・要確認] を使用し、Brix 値として記録した。酸度は [酸度計のメーカー・型番、または滴定法の詳細・要確認] によって測定し、単位は [要確認] とした。

各画像には、トマトの位置を示す境界ボックス、糖度、酸度を教師ラベルとして付与した。同一個体を複数方向から撮影した場合は、同一の個体番号を付与して管理した。

Missing figure: System Overview (fig_system_overview.pdf)

Fig. 1. 提案システム全体構成図.

Missing figure: PBL Process (fig_pbl_process.pdf)

Fig. 2. PBL 活動の開発プロセス.

Missing figure: Data Acquisition
(fig_data_acquisition.pdf)

Fig. 3. データ収集および品質測定.

データセットは、学習用データ、学習時検証用データ、および最終評価用データへ分割した。最終評価用データには 136 サンプルを使用した (表 1)。データ収集および品質測定のフロー概念を図 3 に示す。

2.5. UnifiedDetector の構成

本研究で構築した統合モデルを UnifiedDetector と呼ぶ。UnifiedDetector は、物体検出部、領域特徴抽出部、および回帰部の三つから構成される。

物体検出部には YOLOv10s を使用した。YOLOv10s は、入力画像からトマトの位置と検出信頼度を出力する。

領域特徴抽出部では、フック機構を用いて YOLOv10s の Layer 16 の出力を取得する。取得した特徴マップと境界ボックスを RoI Align へ入力し、トマト領域に対応する固定サイズの特徴表現を生成する。

回帰部である RegressionHead は、RoI Align によって抽出された特徴量を入力とし、糖度および酸度の二つの

Table 1. データセットの構成

区分	サンプル数	割合
学習用データ	[要確認]	[要確認]
学習時検証用データ	[要確認]	[要確認]
最終評価用データ	136	[要確認]
合計	[要確認]	100 %

連続値を出力する。RegressionHead の詳細な層構成は、[要確認] である。

糖度と酸度は、分類問題ではなく回帰問題として学習した。総損失は、物体検出損失、糖度回帰損失、酸度回帰損失を組み合わせて算出した。酸度回帰損失の重みは 3.0 とした。UnifiedDetector のモデル構成図を図 4 に示す。また、詳細な学習条件を表 2 に示す。

2.6. 従来モデル

比較対象として、以前に構築した Swin Transformer を用いた回帰モデルを使用した。従来モデルでは、糖度および酸度を個別のモデルによって推定し、画像または切り出したトマト画像を直接入力していた。

これに対し、UnifiedDetector では、物体検出器によって特定したトマト領域の中間特徴量を回帰へ利用する。これにより、トマト検出と品質推定を一つの推論処理として実行し、果実領域に対応した特徴表現を回帰へ利用する構成とした。

2.7. 推論結果の表示

出力画像には、検出されたトマトの境界ボックス、予測糖度、予測酸度、検出信頼度を表示した。画像上に数値を直接描画することで、複数のトマトが写っている場合でも、どの果実に対応する予測値であるかを確認できる (図 5)。

Missing figure: UnifiedDetector architecture (fig_unified_detector_architecture.pdf)

Fig. 4. UnifiedDetector のモデル構成.

Table 2. モデルの学習条件

項目	設定
物体検出モデル	YOLOv10s
中間特徴層	Layer 16
領域特徴抽出	RoI Align
回帰出力	糖度, 酸度
入力画像サイズ	[要確認]
エポック数	[要確認]
バッチサイズ	[要確認]
最適化手法	[要確認]
初期学習率	[要確認]
酸度損失重み	3.0
使用 GPU	[要確認]
フレームワーク	[要確認]

Missing figure: Inference Example
(tomato_082_annotated.jpg or
fig_inference_example.png)

Fig. 5. 推論結果の表示例.

Table 3. 酸度推定性能の比較

評価指標	従来 Swin モデル	UnifiedDetector
MAE	0.4990	0.0897
RMSE	0.5800	0.1484
R^2	-2.8570	0.1171
相関係数	ほぼ 0	0.3707

3. Experiments and Evaluation

3.1. 評価条件

提案した UnifiedDetector の推定性能を, 最終評価用データ 136 サンプルを用いて評価した. 各サンプルについて, 糖度および酸度の実測値と予測値を比較した.

評価指標には, 平均絶対誤差, 平均二乗誤差平方根, 決定係数, 平均予測誤差, および Pearson の相関係数を使用した.

実測値を y_i , 予測値を $\hat{y}_i$, サンプル数を n , 実測値の平均を $\bar{y}$ とすると, 平均絶対誤差 (MAE) は式 (1) で表される.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad \dots \quad (1)$$

平均二乗誤差平方根 (RMSE) は式 (2) で表される.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad \dots \quad (2)$$

決定係数 (R^2) は式 (3) で表される.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad \dots \quad (3)$$

平均予測誤差 (Bias) は式 (4) で表される.

$$\text{Bias} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i) \quad \dots \quad (4)$$

さらに, 実測値と予測値の関係を視覚的に確認するため, 糖度および酸度について散布図を作成した.

3.2. 酸度推定結果

従来の Swin Transformer モデルと UnifiedDetector の酸度推定結果を表 3 に示す. また, 従来モデルと UnifiedDetector の酸度推定誤差 (MAE および RMSE) の比較を図 6 に示す.

UnifiedDetector の酸度 MAE は 0.0897 であり, 従来モデルの 0.4990 と比較して 82.0 % 低減した. RMSE は, 従




Fig. 6. 従来の Swin モデルと提案手法 (UnifiedDetector) における酸度推定誤差 (MAE および RMSE) の比較.

Table 4. 酸度の実測値と予測値の分布

項目	実測値	予測値
平均	0.3395	0.3172
標準偏差	0.1580	0.0615
最小値	0.17	0.28
最大値	1.08	0.46

来モデルの 0.5800 から 0.1484 へ低減し、改善率は 74.4 % であった.

決定係数は、従来モデルの -2.8570 から 0.1171 へ改善した. また、相関係数は 0.3707 となり、実測酸度と予測酸度の間に正の関係が確認された.

これらの結果から、物体検出器の中間特徴量と RoI Align を用いてトマト領域の特徴を抽出する構成は、従来モデルと比較して酸度推定誤差を低減できることが確認された.

3.3. 酸度予測値の分布

酸度の実測値と予測値の分布を表 4 に示す. また、実測酸度と予測酸度の分布比較を図 7 に示す.

実測値の平均は 0.3395 、予測値の平均は 0.3172 であり、両者の差は -0.0223 であった. このことから、予測値全体の平均は実測値の平均に近い値となった.

予測値は 0.28 から 0.46 の範囲に分布し、主要なデータ範囲の周辺で安定した出力を示した. 一方、実測値の分布は 0.17 から 1.08 であり、より広い範囲に及んでいた. この結果から、現在のデータ分布を中心とする予測特性が確認された. 品質値の異なるサンプルを含めた評価は、モデルの適用範囲を整理するための拡張項目となる.

3.4. 糖度推定結果

UnifiedDetector による糖度推定結果を表 5 に示す. また、糖度および酸度の実測値と予測値の散布図を図 8 に示す.




Fig. 7. 検証用データ 136 サンプルにおける実測酸度と予測酸度の分布比較. 縦の実線および破線は、それぞれ実測値および予測値の平均値を示す.

Table 5. 糖度推定性能

評価指標	UnifiedDetector
MAE	0.5860 Brix
RMSE	0.8397 Brix
R^2	0.2288
Bias	-0.3886 Brix
相関係数	0.8434

糖度推定における相関係数は 0.8434 であり、実測値と予測値の間に強い正の関係が確認された. この結果から、UnifiedDetector が抽出した画像特徴には、糖度の相対的な高低に関係する情報が含まれていると考えられる.

MAE は 0.5860 Brix, RMSE は 0.8397 Brix であった. また、Bias は -0.3886 Brix であり、予測値が実測値よりもやや低くなる一定の傾向が確認された. 相関関係が強いことから、推定値の校正や品質値の分布を考慮したデータ構成によって、絶対値の一致度をさらに整理できる.

3.5. 推論時間

UnifiedDetector による 1 画像当たりの推論時間は、現在の計算環境において約 90 ms であった. この処理時間には、トマト検出、中間特徴量の取得、RoI Align、糖度および酸度の回帰処理が含まれる.

推論時間を測定した計算環境は、CPU が [要確認]、GPU が [要確認]、メモリが [要確認]、ソフトウェア環境が [要確認] である.

本結果から、物体検出と二つの品質指標の推定を統合した場合でも、短時間で推論処理を実行できることを確認した.

3.6. 評価結果のまとめ

定量評価から、以下の三つの成果が得られた.




Fig. 8. 検証用データ 136 サンプルにおける実測値と予測値の関係. (a) 酸度, (b) 糖度. 破線は理想予測線 $y = x$ を示す.

第一に, UnifiedDetector は, 従来の Swin Transformer モデルと比較して, 酸度推定の MAE および RMSE を大幅に低減した.

第二に, 糖度推定では, 相関係数 0.8434 が得られ, 実測糖度の相対的な変化を捉えられることを確認した.

第三に, トマト検出, 糖度推定, 酸度推定を約 90 ms で実行し, 統合型の推論システムとして動作することを確認した.

4. System Evaluation and PBL Outcomes

4.1. 統合型モデルの有効性

UnifiedDetector の特徴は, 物体検出と品質推定を一つのモデル構成へ統合した点にある. 従来モデルでは, 画像または切り出したトマト画像を個別の回帰モデルへ入力していた. これに対し, UnifiedDetector では, 物体検出器が取得した中間特徴量から, トマト領域に対応する情報を RoI Align によって抽出し, 回帰処理へ利用した.

酸度推定における MAE および RMSE の改善から, 検出されたトマト領域に基づく特徴量が, 品質推定に有効である可能性が示された. また, 物体検出と回帰を統合することで, 複数のモデルを独立して実行する必要がなくなり, 入力画像から結果表示までを一つの処理として実行できた.

本研究で得られた統合モデルを基準とし, 中間特徴層, RoI Align, 回帰ヘッドの構成を個別に比較することで, 各要素の寄与を詳細に分析できる. これは, 本システムの適用条件を明確化するための追加評価項目として位置づけられる.

4.2. 酸度推定の評価

酸度推定では, 従来モデルと比較して大きな誤差低減が得られた. 決定係数が負の値から正の値へ改善し, 相関係数についても正の関係が確認されたことから, Uni-

fiedDetector は, 酸度の変化に関する基礎的な傾向を捉えたと考えられる.

予測値の平均は実測値の平均に近く, 主要なデータ範囲において安定した予測値が得られた. 実測値と比較して予測値の範囲が狭いことは, 現在多く含まれる酸度領域を中心としてモデルが学習した結果と解釈できる.

酸度範囲ごとのサンプル数を考慮したデータ構成や, 酸度範囲に応じた重み付き損失は, モデルの応答範囲を分析するための比較条件となる.

4.3. 糖度推定の評価

糖度推定では, 相関係数 0.8434 が得られた. この結果は, UnifiedDetector が糖度の高いサンプルと低いサンプルの相対的な関係を捉えていることを示している.

Bias は -0.3886 Brix であり, 全体として予測値がやや低くなる一定の傾向が確認された. 一方, 相関関係が強いことから, モデル出力に対する校正処理を検討することで, 絶対値の推定特性をさらに整理できる.

本システムは, 糖度計を直接置き換える測定装置ではなく, 多数の果実から糖度傾向を簡易的に把握し, 詳細測定を行う対象を選択するための品質評価支援システムとして位置づけられる.

4.4. 品質評価支援システムとしての位置づけ

本システムは, 果実内部の化学成分を直接測定する装置ではなく, 画像と品質値の関係を学習し, 品質指標を推定するシステムである. したがって, 糖度計や酸度計による実測を補助する仕組みとして利用することが適切である.

例えば, 多数のトマト画像を本システムへ入力し, 予測糖度や予測酸度が特徴的な果実を抽出した後, 選択した果実を専用機器で測定することで, 測定作業を重点化できる.

また, 果実ごとに境界ボックスと品質値を表示できるため, 複数果実を含む画像から, 品質傾向を視覚的に確

Table 6. PBL 活動において統合された STEM/STEAM 分野

分野	PBL 活動における内容
Science	トマトの成熟, 糖度, 酸度, 栽培条件の理解
Technology	RGB 画像, 物体検出, 深層学習, データ管理
Engineering	課題設定, 要件定義, モデル統合, システム実装
Arts	推定結果の可視化, 利用者を考慮した表示設計
Mathematics	回帰分析, 損失関数, MAE, RMSE, 決定係数, 相関分析

認できる. 推論時間が約 90 ms であることから, 画像取得後に短時間で結果を提示する利用形態にも適している.

4.5. PBL 活動として得られた成果

本研究は, 学生主体の PBL 活動によって実施された. 本活動の主要な成果は, トマトの検出, 糖度推定, および酸度推定を統合した AI システムを実際に構築し, 136 サンプルを用いた定量評価まで実施した点にある.

学生は, 農業従事者へのヒアリングを通して, 後継者不足, 経験値への依存, アナログな作業記録などの課題を整理した. その後, トマト品質評価の支援を対象として, 画像取得, 品質測定, データセット構築, AI モデル設計, 学習, 評価を行った.

本活動では, 既存の教育用データセットを用いるのではなく, 学生自身が画像と品質値を収集した. そのため, 撮影条件のばらつき, 測定値の分布, ラベルの管理, 学習データと評価データの分割など, 実際の AI システム開発で生じる課題に対応する必要があった.

酸度推定では, 従来モデルから MAE および RMSE を大幅に低減できた. 糖度推定では, 実測値と予測値の間に強い正の相関が得られた. これらの結果を分析することで, モデル構造だけでなく, データ分布, 測定方法, 評価指標が AI 性能に影響することを確認した.

以上から, 本 PBL 活動では, 農業上の課題を技術要件へ変換し, 複数分野の知識を統合してシステムを構築し, 定量的な評価結果を得るところまで到達した. 本論文では, PBL を教育効果の比較実験として扱うのではなく, 技術成果を生み出した学生主体の開発プロセスとして記述する.

4.6. PBL 活動において統合された STEM/STEAM 分野

本 PBL 活動では, トマトの糖度, 酸度, 成熟に関する科学的知識, RGB カメラや深層学習に関する情報技術, モデル統合やシステム実装に関する工学的設計, 推定結果の表示に関する可視化, 回帰評価指標に関する数学的分析を組み合わせた. このため, 本活動は, 複数分野の知識を実際の課題解決へ統合した Hands-on STEM/STEAM 型の PBL として位置づけられる. 表 6 に, PBL 活動において統合された STEM/STEAM 分野の詳細を示す.

4.7. 本研究から導かれる発展可能性

本研究から, システム性能と適用範囲を整理するための発展項目として, データセットの多様化, 測定手順の

標準化, モデル構成の比較, および外部情報との統合が挙げられる.

データセットについては, 糖度および酸度の値が一部の範囲へ集中しないよう, 品質値の分布を考慮したサンプル構成が有効である. また, 品種, 収穫時期, 撮影条件, 撮影機器を変えたデータを用いることで, モデルの適用条件を評価できる.

測定手順については, 糖度計および酸度計の校正方法, 果汁の採取方法, 測定回数, 測定温度を統一することで, 教師ラベルの一貫性を高められる.

モデル構造については, 画像全体を用いる回帰モデル, 切り出し画像を用いる回帰モデル, RoI Align を使用しないモデル, 異なる中間層を使用するモデルを比較することで, UnifiedDetector の各構成要素が推定性能へ与える効果を分析できる.

温度, 湿度, 日射量, CO₂ 濃度などの環境情報は, 本研究では学習入力に含めていない. これらは, RGB 画像のみを用いるモデルとの比較対象となり得る. また, 品質推定結果へ位置情報を付与することで, 畝または株ごとの品質分布を電子 MAP 上へ記録する応用も考えられる. これらの機能は本論文の評価対象ではなく, 画像ベース推定システムから派生する研究項目である.

5. Conclusion

本研究では, RGB 画像からトマトを検出し, 糖度および酸度を同時に推定する統合型 AI システム UnifiedDetector を開発した. UnifiedDetector は, YOLOv10s, 中間特徴量抽出, RoI Align, および RegressionHead によって構成される.

136 サンプルを用いた評価の結果, 酸度推定では, MAE 0.0897, RMSE 0.1484, 決定係数 0.1171, 相関係数 0.3707 が得られた. 従来の Swin Transformer モデルと比較して, MAE は 82.0 %, RMSE は 74.4 % 低減した.

糖度推定では, MAE 0.5860 Brix, RMSE 0.8397 Brix, 決定係数 0.2288, 相関係数 0.8434 が得られた. この結果から, UnifiedDetector は, 糖度の相対的な高低に関係する傾向を捉えることができた.

また, 提案システムは, トマト検出, 糖度推定, 酸度推定を約 90 ms で実行し, 統合型の推論システムとして動作することを確認した.

本システムは, 学生主体の PBL 活動によって開発された. 学生は, 農業従事者へのヒアリング, 課題設定, 画像および測定値の収集, AI モデルの設計, 実装, 評価を分担して行った. その結果, 単なるモデル試作にとどま

らず、トマト検出、糖度推定、酸度推定を統合したシステムを構築し、定量的な性能評価を行うことができた。

本活動は、農業科学、画像処理、深層学習、システム工学、データ可視化、統計分析を統合した PBL の成果であり、実社会の課題に対して学生が主体的に技術開発を行った事例として位置づけられる。本研究で構築した画像ベース推定システムは、トマトの品質傾向を簡易的に把握し、詳細測定を行う果実の選択を支援する基盤となる。

Acknowledgments

本研究の実施に当たり、ヒアリング、データ収集、および実験に協力いただいた農業従事者の皆様に感謝する。また、本システムの開発および評価に参加したプロジェクトメンバー、ならびに指導いただいた教職員に感謝する。本研究は、[研究費、採択事業、コンテスト等の名称・要確認] の支援を受けて実施した。

References:

- [1] Y. Xiang, Q. Chen, Z. Su, L. Zhang, Z. Chen, G. Zhou, Z. Yao, Q. Xuan, and Y. Cheng, "Deep learning and hyperspectral images based tomato soluble solids content and firmness estimation," *Frontiers in Plant Science*, Vol.13, p. 860656, 2022. <https://doi.org/10.3389/fpls.2022.860656>
- [2] M. Zhao, H. Cang, H. Chen, C. Zhang, T. Yan, Y. Zhang, P. Gao, and W. Xu, "Determination of quality and maturity of processing tomatoes using near-infrared hyperspectral imaging with interpretable machine learning methods," *LWT*, Vol. 183, p. 114861, 2023. <https://doi.org/10.1016/j.lwt.2023.114861>
- [3] C. Dai, J. Sun, X. Huang, X. Zhang, X. Tian, W. Wang, J. Sun, and Y. Luan, "Application of hyperspectral imaging as a nondestructive technology for identifying tomato maturity and quantitatively predicting lycopene content," *Foods*, Vol.12, No.15, p. 2957, 2023. <https://doi.org/10.3390/foods12152957>
- [4] A. A. de Brito, F. Campos, A. dos Reis Nascimento, C. Damiani, F. A. da Silva, G. H. de Almeida Teixeira, and L. C. Cunha Júnior, "Non-destructive determination of color, titratable acidity, and dry matter in intact tomatoes using a portable vis-nir spectrometer," *Journal of Food Composition and Analysis*, Vol. 107, p. 104288, 2022. <https://doi.org/10.1016/j.jfca.2021.104288>
- [5] T. Kim, D.-H. Lee, K.-C. Kim, T. Choi, and J. M. Yu, "Tomato maturity estimation using deep neural network," *Applied Sciences*, Vol.13, No.1, p. 412, 2023. <https://doi.org/10.3390/app13010412>
- [6] P. Li, J. Zheng, P. Li, H. Long, M. Li, and L. Gao, "Tomato maturity detection and counting model based on mhsa-yolov8," *Sensors*, Vol.23, No.15, p. 6701, 2023. <https://doi.org/10.3390/s23156701>
- [7] A. Khan, T. Hassan, M. Shafay, I. Fahmy, N. Werghi, S. Mudigansalage, and I. Hussain, "Tomato maturity recognition with convolutional transformers," *Scientific Reports*, Vol.13, p. 22885, 2023. <https://doi.org/10.1038/s41598-023-50129-w>
- [8] S. Wang, J. Xiang, D. Chen, and C. Zhang, "A method for detecting tomato maturity based on deep learning," *Applied Sciences*, Vol.14, No.23, p. 11111, 2024. <https://doi.org/10.3390/app142311111>
- [9] A. Kamilaris and F. X. Prenafeta-Boldú, "Deep learning in agriculture: A survey," *Computers and Electronics in Agriculture*, Vol. 147, pp. 70-90, 2018. <https://doi.org/10.1016/j.compag.2018.02.016>
- [10] K. Sharma and S. K. Shivandu, "Integrating artificial intelligence and internet of things (iot) for enhanced crop monitoring and management in precision agriculture," *Sensors International*, Vol.5, p. 100292, 2024. <https://doi.org/10.1016/j.sintl.2024.100292>
- [11] H. Kwon and Y. Lee, "A meta-analysis of stem project-based learning on creativity," *STEM Education*, Vol.5, No.2, pp. 275-290, 2025. <https://doi.org/10.3934/steme.2025014>
- [12] D. T. K. Oanh and T. D. H. Dang, "Effect of steam project-based learning on engineering students' 21st century skills," *European Journal of Educational Research*, Vol.14, No.3, pp. 705-721, 2025. <https://doi.org/10.12973/eu-jer.14.3.705>



Name:
[要確認]

ORCID:
[要確認]

Affiliation:
[要確認]

Address:
[要確認]

Brief Biographical History:
[要確認]

Main Works:
[要確認]

Membership in Academic Societies:
[要確認]